Proyecto completo del PSet 1

Wilmer Puerta · 12 de noviembre de 2026

Estado: propuesta revisada y auditoría descriptiva. No se entrenaron modelos ni ejecutaron intervenciones.

1. Ideas de Proyectos

1.1. Predicción temprana del riesgo de reprobación y seguimiento de la actividad digital para priorizar el acompañamiento académico: estudio con OULAD.

1.2. Detección de segmentos compatibles con fibrilación auricular para priorizar la revisión en programas de monitoreo cardiovascular.

1.3. Predicción del crecimiento anual de ingresos por cliente para priorizar oportunidades comerciales en telecomunicaciones.

1.1. Predicción temprana del riesgo de reprobación y seguimiento de la actividad digital para priorizar el acompañamiento académico: estudio con OULAD.

1.1.1. Idea:

Desarrollar un prototipo de alerta temprana con OULAD [1] para evaluar si las características longitudinales de interacción digital mejoran la identificación de estudiantes que posteriormente reprueban un módulo, frente al uso exclusivo de características estáticas. El contexto será una universidad hipotética con capacidad limitada de acompañamiento académico.

El prototipo actualizará el riesgo en las semanas 2, 4, 6 y 8 y mostrará su evolución para apoyar la priorización de tutorías. Estas semanas corresponden a la ventana de observación temprana seleccionada.

1.1.2. Problema:

Negocio. Un acompañamiento principalmente posterior a la reprobación limita la intervención preventiva y puede aumentar las necesidades de recuperación académica. Una clasificación inicial basada en antecedentes fijos omite cambios posteriores del estudiante. La universidad necesita actualizar la identificación del riesgo para focalizar recursos limitados y detectar casos que inicialmente quedarían fuera del apoyo.

Ciencia de datos. Se compararán regresión logística multinomial y Random Forest con variables estáticas, frente a los mismos algoritmos enriquecidos con actividad digital longitudinal. Se evaluará si el nivel, la regularidad y los cambios de interacción aportan mejora predictiva bajo condiciones comparables. La actividad digital se tratará como una señal contextual, no como prueba directa de compromiso.

1.1.3. Predicción:

Para cada estudiante–módulo–edición activo en el corte, se estimará la probabilidad del resultado final: reprobación (Fail), retiro (Withdrawn) o aprobación (Pass/Distinction). La prioridad será el riesgo de reprobación. Se utilizarán únicamente datos disponibles hasta cada corte; el retiro del módulo se distinguirá del abandono institucional.

Se evaluarán PR-AUC, precisión y recobrado para reprobación, entrenando con ediciones anteriores y probando con posteriores. La meta provisional es detectar un 10% más de casos, en términos relativos, frente al modelo estático en la semana 8, con igual capacidad de atención. Los cortes anteriores mostrarán anticipación; la mejora deberá comprobarse.

1.1.4. Datos:

OULAD es un dataset público anonimizado, con acceso y descarga confirmados por el equipo. Se utilizarán studentInfo.csv para antecedentes y resultado final; studentVle.csv para interacciones diarias; y vle.csv, courses.csv y studentRegistration.csv para contextualizar recursos, duración y elegibilidad. Se construirán indicadores quincenales de actividad, inactividad y tendencia a partir de los campos documentados en [2].

La auditoría descriptiva local documenta volumen, faltantes, uniones y estudiantes únicos; queda pendiente validar cobertura semántica y particiones temporales. Se excluirá información futura y se preservará la atribución requerida por CC BY 4.0. La capacidad tutorial será simulada, pues no existen costos ni resultados de intervenciones confirmados. La descripción de los datos y su licencia se documentan en [1], [2].

1.1.5. Acción:

Cada dos semanas, un tutor revisaría una lista ordenada por riesgo para decidir contactos, orientación o apoyo académico. La capacidad simulada inicial será el 10% de estudiantes elegibles por corte, con escenarios del 5% y 20%. El umbral dependerá de esa capacidad; el criterio humano determinará la intervención.

Se compararán casos identificados, omitidos y anticipación con el mismo presupuesto de contactos; las revisiones repetidas consumirán capacidad y cada matrícula contará una sola vez en TP acumulados; se informarán además personas únicas. El resultado demostrable será una mejor focalización potencial. Reducir reprobación o costos requerirá un piloto posterior que evalúe el efecto de las tutorías.

1.1.6. Riesgos:

• **Técnico — Mejora insuficiente (alta).** Las variables longitudinales podrían no superar al baseline. Se contrastarán resultados bajo condiciones equivalentes y con incertidumbre; si no aportan valor, se conservará el enfoque estático y se reportará el resultado.

• **Técnico — Fuga de información (crítica).** Datos futuros o estudiantes repetidos podrían inflar el desempeño. Se auditarán fechas y particiones; si se detectan problemas, se reconstruirá la evaluación antes de concluir.

• **Técnico — Interpretación incorrecta de la actividad (alta).** Menos clics podrían reflejar cambios del calendario o registros incompletos. Se revisarán cobertura y contexto del módulo; las señales ambiguas se ajustarán o excluirán.

• **Negocio — Capacidad tutorial poco realista (alta).** Las listas podrían exceder los recursos disponibles. Se analizarán presupuestos y contactos repetidos; una adopción futura requerirá validar la capacidad con tutores y ajustar la frecuencia de atención.

• **Negocio — Intervenciones sin impacto (alta).** Detectar riesgo podría no mejorar el resultado académico. Un piloto posterior comparará intervenciones y resultados; hasta entonces, las conclusiones se limitarán a predicción y focalización potencial.

• **Adopción — Alertas injustificadas o sobrecarga (alta).** Los errores podrían afectar la confianza o perjudicar a ciertos grupos. Se revisarán errores por subgrupos y carga de alertas; se ajustará la priorización manteniendo revisión humana y acceso habitual al apoyo.

1.2. Detección de segmentos compatibles con fibrilación auricular para priorizar la revisión en programas de monitoreo cardiovascular.

1.2.1. Idea:

Proponer un sistema de apoyo que identifique segmentos de señal cardíaca compatibles con fibrilación auricular y los priorice para revisión profesional. Su aplicación prevista sería un programa de monitoreo de pacientes con enfermedad cardiovascular crónica, coordinado por una aseguradora o un prestador de salud.

El proyecto se enfocará en la detección de una alteración presente en el registro. La prevención de complicaciones será un beneficio potencial que requerirá evaluación posterior. El entorno de desarrollo, las herramientas y la incorporación de una simulación IoT se definirán durante el desarrollo de la propuesta.

1.2.2. Problema:

Negocio. En un programa hipotético de monitoreo cardiovascular, revisar grandes volúmenes de registros puede superar la capacidad disponible y demorar la identificación de segmentos relevantes. La organización necesita focalizar la revisión profesional para reconocer posibles episodios de fibrilación auricular y decidir oportunamente qué casos requieren valoración adicional.

Ciencia de datos. Se plantea clasificar segmentos de señal cardíaca según su compatibilidad con fibrilación auricular, utilizando anotaciones reales como referencia. Se evaluará si esa clasificación mejora la selección de registros para revisión frente a una estrategia de referencia por definir. La detección automatizada apoyará el juicio profesional sin establecer por sí sola un diagnóstico.

1.2.3. Predicción:

La unidad de análisis será un segmento de señal cardíaca asociado a un paciente. La salida será una puntuación de compatibilidad con fibrilación auricular presente en ese segmento. La fuente candidata dispone de anotaciones de ritmo que permitirían construir el resultado objetivo [3], [4], sujeto a verificar su contenido y calidad.

Durante el desarrollo se definirán ventanas, características, algoritmos, métricas, baseline y evaluación con pacientes distintos entre entrenamiento y prueba. El criterio de negocio será identificar más segmentos relevantes con capacidad de revisión comparable. La meta cuantitativa se establecerá tras inspeccionar los datos; no se compromete anticipación de urgencias ni ahorro económico demostrado.

1.2.4. Datos:

Se ha identificado Icentia11k como fuente pública candidata. Su documentación describe señales ECG de un monitor portátil y anotaciones de ritmos, incluida fibrilación auricular [3], [4]. **El equipo aún no dispone de los datos descargados ni ha inspeccionado señales o anotaciones.** La adquisición y auditoría quedan para la etapa de desarrollo.

Se verificará cobertura, calidad, condiciones de uso y representatividad para pacientes con enfermedad cardiovascular crónica. No se dispone de costos ni resultados de intervenciones. Se explorará después la simulación de transmisión o datos de dispositivos IoT; cualquier componente sintético se identificará y no sustituirá la evaluación con señales y etiquetas reales.

1.2.5. Acción:

El sistema propondría una lista priorizada de segmentos para que un profesional revise la señal y determine si corresponde una valoración adicional. El umbral y la capacidad de revisión se definirán posteriormente. La organización conservaría sus procedimientos habituales de atención y el profesional mantendría la decisión clínica.

La utilidad se evaluaría por la identificación de segmentos relevantes, los casos omitidos y la carga de revisión frente al baseline acordado. Las alertas repetidas deberán contabilizarse. La reducción de tiempos, costos o complicaciones requeriría mediciones adicionales y una evaluación de las intervenciones, fuera de lo demostrable únicamente con clasificación retrospectiva.

1.2.6. Riesgos:

• **Técnico — Datos insuficientes o inadecuados (alta).** La fuente podría no aportar señales y etiquetas utilizables. Se inspeccionará una muestra y su cobertura durante el desarrollo; si falla, se acotará el conjunto o se buscará otra fuente antes de entrenar.

• **Técnico — Evaluación optimista (alta).** Segmentos del mismo paciente en entrenamiento y prueba podrían inflar el desempeño. Se verificará la separación por paciente al diseñar la evaluación; cualquier solapamiento indebido exigirá rehacerla.

• **Técnico — Simulación IoT poco representativa (alta).** Datos sintéticos, ruido o pérdidas simuladas podrían no reproducir dispositivos reales. Se contrastarán con señales observadas durante el desarrollo; la simulación quedará limitada a pruebas técnicas si no puede validarse su realismo.

• **Negocio — Exceso de alertas o casos omitidos (alta).** El sistema podría sobrecargar la revisión o pasar por alto segmentos relevantes. Se evaluarán errores y carga frente al baseline; se ajustará la priorización o se descartará su utilidad si no mejora el proceso.

• **Negocio — Detección sin beneficio posterior (alta).** Priorizar registros podría no reducir complicaciones ni costos. Un piloto posterior deberá evaluar acciones y resultados; mientras tanto, las conclusiones se limitarán a desempeño y focalización potencial.

• **Adopción — Población poco representativa (alta).** Los pacientes del dataset podrían diferir del programa previsto. Se revisarán características y documentación disponibles; si no se acredita representatividad, se limitará la conclusión a la población observada y se requerirá validación externa.

1.3. Predicción del crecimiento anual de ingresos por cliente para priorizar oportunidades comerciales en telecomunicaciones.

1.3.1. Idea:

Desarrollar un modelo que estime la probabilidad de crecimiento, estabilidad o disminución de los ingresos efectivos de cada cliente durante el siguiente año calendario. Se utilizará el historial mensual de ingresos por producto o servicio de una empresa de telecomunicaciones para apoyar la asignación de recursos comerciales.

La evolución de ingresos y la composición de servicios permitirán caracterizar oportunidades de expansión. La clasificación por tamaño económico complementará la predicción, con segmentos por

definir. El crecimiento incluirá ajustes tarifarios, aumentos en servicios existentes y servicios que comienzan a generar ingresos, conforme al criterio comercial descrito por el equipo.

1.3.2. Problema:

Negocio. La empresa necesita distribuir ejecutivos, campañas y atención especializada entre clientes con distinto potencial de crecimiento. El ingreso actual identifica el tamaño de una cuenta, pero no determina su evolución futura. Incorporar esa perspectiva permitiría focalizar los recursos disponibles; el proceso actual de asignación deberá documentarse antes de evaluar su mejora.

Ciencia de datos. Se plantea una clasificación de tres resultados futuros utilizando tendencias, variabilidad y composición mensual de ingresos, junto con cantidad de servicios con ingresos y antigüedad observable. Se evaluará si el modelo mejora la identificación de clientes que crecen frente a una regla sencilla basada en tendencia histórica, por definir durante el desarrollo.

1.3.3. Predicción:

Para cada cliente activo al cierre de un año, se estimarán las probabilidades de crecimiento, estabilidad y disminución de sus ingresos acumulados del año siguiente respecto al año de referencia. La banda de estabilidad y el tratamiento de historiales parciales o bases nulas se definirán con análisis de datos y criterio comercial.

La evaluación será temporal, con ventanas comparables: por ejemplo, aprender con información de 2020 y resultados de 2021, evaluar con información de 2021 y resultados de 2022, y después pronosticar 2023. Se medirán F1-macro y precisión y recobrado de crecimiento. Los años son ilustrativos; tres años de historia limitan las transiciones anuales evaluables.

1.3.4. Datos:

El equipo confirma disponer de registros internos de ingresos efectivos por cliente, producto o servicio y mes durante tres años. Se verificará el identificador de cliente, fechas, continuidad, definición de cartera activa y consistencia de categorías. El ingreso total se obtendrá agregando los servicios de cada cliente en cada período.

Queda pendiente auditar volumen, calidad, faltantes, ajustes contables y permisos de uso académico y confidencialidad. Se distinguirán ingreso cero, registro ausente y salida del cliente. No se requieren reclamos ni NPS. La fuente es empresarial interna, informada por el equipo; su identificación documental y restricciones se completarán sin divulgar información confidencial.

1.3.5. Acción:

Al iniciar el año, el responsable comercial utilizaría las probabilidades junto con el tamaño económico y la composición de servicios para priorizar cuentas. Podría asignar ejecutivos senior, ampliar atención o diseñar campañas y ofertas proactivas. La intensidad de la gestión dependerá de la capacidad disponible y del juicio comercial.

La utilidad inicial será identificar más clientes que posteriormente crecen con un presupuesto comercial comparable al baseline; la meta cuantitativa se definirá tras inspeccionar los datos. Se distinguirá crecimiento observado de ingreso incremental causado por la intervención, cuya demostración requeriría un piloto posterior con un grupo de comparación adecuado.

1.3.6. Riesgos:

• **Técnico — Pocas transiciones anuales (alta).** Tres años podrían no cubrir suficientes ciclos para generalizar. Se verificará la cobertura temporal y la estabilidad de resultados; si resulta insuficiente, se ampliará el historial o se limitarán las conclusiones al período evaluado.

• **Técnico — Crecimiento aparente por historial parcial (alta).** Comparar pocos meses de ingresos con un año completo podría inflar el crecimiento. Se analizarán antigüedad y meses observados; los clientes recientes se tratarán por separado o mediante una comparación ajustada y documentada.

• **Técnico — Calidad y fuga de información (alta).** Faltantes, cambios de categorías o variables posteriores al corte podrían distorsionar resultados. Se auditarán registros y fechas; se corregirán las agregaciones y se reconstruirá la evaluación cuando corresponda, manteniendo las salidas reales como parte del resultado.

• **Negocio — Crecimiento sin respuesta a la gestión (alta).** Un cliente podría aumentar ingresos por tarifas u otros factores aun sin intervención. Un piloto posterior evaluará el efecto comercial incremental; hasta entonces, la conclusión se limitará a identificar potencial y focalizar cuentas.

• **Negocio — Priorización poco rentable (alta).** Las cuentas con mayor probabilidad de crecer podrían aportar incrementos pequeños o exigir demasiados recursos. Se analizarán importes, carga y costos cuando estén disponibles; se ajustará la asignación sin equiparar probabilidad de crecimiento con rentabilidad.

• **Negocio — Cambios tarifarios o de mercado (alta).** Nuevas condiciones podrían alterar los patrones históricos. Se revisarán resultados por período y cambios de política comercial; ante degradación, se actualizará el modelo y se recalibrará la estrategia de priorización.

• **Datos y adopción — Restricciones de uso (alta).** La disponibilidad interna podría no implicar autorización académica. Se confirmarán permisos y medidas de anonimización; si no se autoriza el uso, se limitará el alcance a datos permitidos o se reconsiderará la viabilidad.

2. Comparación y selección de la idea más viable

2.1. Metodología de comparación

Se comparan las tres ideas con los seis criterios establecidos, utilizando **Alto (3), Medio (2) y Bajo (1)**. Alto indica una condición favorable y suficientemente sustentada para diseñar el proyecto; Medio refleja una condición plausible con verificaciones relevantes pendientes; Bajo corresponde a una limitación que impide sostener su viabilidad actual. Las calificaciones son juicios de diseño basados en la información disponible, no resultados de experimentación.

Los criterios tienen el mismo peso y se suman sobre un máximo de 18 puntos. En caso de empate se prioriza la menor incertidumbre para construir y evaluar el proyecto, revisando acceso a datos, target, evaluación y alcance. El valor y la acción se califican por su utilidad y concreción potenciales; ninguna idea ha demostrado todavía impacto causal en una organización.

2.2. Matriz comparativa y justificación

Criterio	Idea 1: acompañamiento académico	Idea 2: fibrilación auricular	Idea 3: crecimiento de ingresos
Valor de negocio	**Medio (2).** Mejoraría la focalización de tutorías, pero la institución es hipotética y no se han confirmado capacidad, costos ni necesidades operativas.	**Medio (2).** Podría mejorar la revisión de registros; falta validar la necesidad y el beneficio operativo con un prestador o aseguradora.	**Alto (3).** Se vincula directamente con ingresos y asignación de recursos de una empresa real, bajo un criterio comercial descrito por el equipo. El beneficio incremental sigue pendiente de prueba.
Acceso a datos	**Alto (3).** OULAD está descargado y su acceso público está confirmado; la auditoría descriptiva local está documentada; resta validación temporal y de cobertura.	**Medio (2).** Icentia11k está identificado y documentado, pero el equipo todavía no lo ha descargado ni inspeccionado.	**Medio (2).** El equipo dispone de tres años de registros, pero falta confirmar autorización de uso académico y condiciones de confidencialidad.
Target	**Alto (3).** El resultado final está documentado y permite distinguir reprobación, retiro y aprobación [1], [2].	**Alto (3).** La fuente documenta anotaciones de fibrilación auricular [3], [4]. La construcción de etiquetas por ventana deberá verificarse al inspeccionar los datos.	**Alto (3).** El cambio anual de ingresos es reconstruible con las mediciones históricas disponibles, sujeto a continuidad, banda de estabilidad y tratamiento de historiales parciales.
Acción	**Medio (2).** Se propone priorizar revisión y contacto tutorial; la capacidad y el proceso institucional son simulados.	**Medio (2).** Se propone priorizar segmentos para revisión profesional; faltan capacidad, umbral y validación del flujo clínico.	**Alto (3).** Existen decisiones concretas de asignación de ejecutivos, campañas y ofertas. Su implementación y presupuesto deberán acordarse con la empresa.
Evaluación	**Alto (3).** Está definida la comparación estática/longitudinal, los cortes temporales y las métricas con presupuesto comparable. Es evaluable retrospectivamente.	**Medio (2).** Las anotaciones permiten evaluar detección, pero ventanas, baseline y métricas todavía están por definir.	**Medio (2).** Puede contrastarse la predicción con resultados anuales observados; tres años ofrecen pocas transiciones temporales para evaluar estabilidad.
Alcance	**Alto (3).** Dos clasificadores, cuatro cortes y características agregadas permiten acotar un MVP con preparación de datos, modelo, despliegue demostrativo y monitoreo.	**Medio (2).** El procesamiento de ECG, la selección de segmentos y la posible simulación IoT añaden complejidad todavía no dimensionada.	**Alto (3).** Una clasificación anual con datos tabulares y una salida de priorización comercial permite acotar un MVP; no requiere integrar CRM ni ejecutar campañas reales.
Total / 18	**16**	**13**	**16**

La puntuación de target refleja que el resultado existe o puede reconstruirse; no implica que las etiquetas hayan sido auditadas. El alcance Alto de las ideas 1 y 3 presupone un MVP demostrativo, cuyo producto y entorno se definirán en la propuesta. La validación de ahorro, reducción de reprobación o incremento comercial atribuible a intervenciones requeriría pilotos posteriores.

2.3. Decisión y justificación de la selección

Se selecciona la idea 1: predicción temprana del riesgo de reprobación para priorizar el acompañamiento académico. La decisión ha sido acordada por el equipo. Aunque las ideas 1 y 3 empatan con 16 de 18 puntos, se aplica el criterio de desempate de menor incertidumbre para construir y evaluar el proyecto: OULAD ya está descargado, el resultado está documentado y la comparación estática/longitudinal está delimitada.

La idea 1 ofrece la combinación más favorable de datos accesibles, un target observable, una acción concreta de revisión tutorial y un alcance acotado. Su valor potencial consiste en focalizar mejor el acompañamiento académico. La evaluación retrospectiva permitirá comparar predicciones y priorización con capacidad equivalente; la auditoría descriptiva se documenta en el apartado de evidencia local; continúa pendiente validar la cobertura semántica.

La selección no presupone que el modelo alcanzará la mejora relativa del 10% ni que las tutorías reducirán efectivamente la reprobación. El proceso institucional será simulado y la meta predictiva deberá comprobarse. Estas limitaciones están identificadas y permiten mantener un alcance evaluable sin depender de un piloto institucional para completar el proyecto académico.

La idea 3 conserva una aplicación empresarial directa y queda como alternativa para un desarrollo posterior. Su principal limitación es la profundidad temporal: tres años de ingresos mensuales no equivalen a tres ejemplos anuales completos por cliente, porque cada ejemplo requiere información previa y un año posterior observado. Con ventanas anuales comparables, el esquema planteado permite una transición inicial para entrenamiento y otra para evaluación, lo que limita comprobar estabilidad entre años.

Un mayor número de clientes puede aportar observaciones, pero no reemplaza la diversidad de ciclos temporales. También quedan pendientes la autorización de uso académico y la auditoría de continuidad de los registros. Ampliar la historia fortalecería la evaluación de la idea 3; con los datos actuales podría realizarse una evaluación inicial, reconociendo estas restricciones. Su valor comercial no elimina esa incertidumbre frente a la idea 1.

La idea 2 permanece como una oportunidad válida, con menor preparación actual: falta adquirir e inspeccionar las señales y definir el diseño de evaluación. Su menor puntuación refleja esas dependencias y la complejidad por dimensionar, no una menor importancia del problema de salud.

La propuesta detallada de la sección 3 desarrolla la idea 1 seleccionada.

3. Propuesta del proyecto seleccionado

Título: Predicción temprana del riesgo de reprobación mediante características longitudinales de actividad digital para priorizar el acompañamiento académico.

Esta sección desarrolla el diseño ampliado de la idea 1 seleccionada. Es el respaldo de detalle de la propuesta breve de 1 a 2 páginas y del pitch de seis diapositivas. Las decisiones metodológicas aquí propuestas se verificarán al auditar los datos; no se presentan resultados de modelos ni de intervenciones ya ejecutadas.

3.1. Problema de negocio y formulación de ciencia de datos

3.1.1. Situación actual, afectados y oportunidad

Se plantea una universidad hipotética con enseñanza apoyada en una plataforma digital y capacidad limitada de acompañamiento. En este escenario, la revisión de antecedentes al inicio del módulo y la atención posterior a dificultades manifiestas podrían dejar sin contacto preventivo a estudiantes cuyo riesgo cambia durante el período. El proceso institucional descrito es un supuesto de aplicación, no una práctica atribuida a The Open University ni a todas las universidades.

El problema afecta a estudiantes que podrían recibir apoyo tardíamente, a tutores que deben distribuir tiempo limitado y a responsables académicos que necesitan justificar la asignación de recursos. Reprobar puede generar necesidades de recuperación y retrasos en el avance académico; no se asumirá que cada reprobación produce abandono, un costo fijo o una sanción institucional.

La decisión que se busca mejorar es **a quién revisar y contactar durante el módulo**. Los antecedentes estáticos permiten una primera estimación, pero no registran cambios posteriores de actividad. Incorporar observaciones quincenales permitiría revisar la prioridad de atención. Una caída de interacción será una señal candidata que debe contextualizarse, no una prueba de desinterés o dificultad por sí sola.

Cadena de valor: dificultades potencialmente no detectadas → estimación de riesgo de reprobación → priorización de revisión según capacidad → contacto y evaluación del tutor → mejor focalización potencial del acompañamiento. La mejora de resultados educativos dependerá de la intervención y requerirá evidencia adicional.

3.1.2. Objetivos y pregunta de investigación

Objetivo de negocio: mejorar la focalización del acompañamiento preventivo, identificando más casos de futura reprobación con una capacidad de revisión comparable. El proyecto evaluará una política de priorización retrospectiva; no prometerá reducción de reprobación ni ahorro institucional con datos que no registran el efecto de las tutorías.

Objetivo analítico: determinar si añadir características longitudinales de actividad digital mejora la predicción frente al uso exclusivo de variables estáticas, y cómo cambia ese aporte entre las semanas 2, 4, 6 y 8. La comparación utilizará los mismos algoritmos, población y criterios de evaluación en cada corte.

Pregunta: ¿la información sobre nivel, regularidad y evolución de la actividad digital permite detectar más estudiantes que posteriormente reprueban, a igualdad de cupos de revisión? La hipótesis admite que el aporte sea pequeño, inconsistente o nulo. Un resultado negativo bien evaluado también responderá la pregunta de investigación.

3.1.3. Unidad, población, target y horizonte

Elemento	Definición propuesta
Unidad de predicción	Una matrícula estudiante–módulo–edición. El mismo estudiante puede tener varias matrículas; su identificador sirve para vinculación y control de evaluación, no como predictor.
Población inicial	Matrículas registradas hasta el inicio oficial del módulo. Esta delimitación permite comparar con una estimación estática inicial; las inscripciones posteriores se cuantificarán y quedarán fuera del análisis principal.
Elegibilidad por corte	Matrículas de la población inicial que no se hayan retirado al finalizar el día del corte. Quienes se retiren después permanecerán con su resultado futuro correspondiente.
Target	Resultado final del mismo módulo: Fail → reprobación; Withdrawn → retiro; Pass o Distinction → aprobación. Las categorías proceden del resultado documentado en OULAD [1], [2].
Salida	Probabilidades de las tres categorías. La probabilidad de reprobación será la señal principal para ordenar la revisión. Retiro no equivale a aprobación ni demuestra abandono definitivo de la universidad.
Cortes	Final de los días 14, 28, 42 y 56 desde el inicio. La información disponible hasta ese día se utilizará para una revisión posterior al corte.
Horizonte	Desde cada corte hasta el cierre del mismo módulo. Las ocho semanas son una ventana temprana, no la duración completa del curso; el horizonte se calculará por edición.

La fecha futura de retiro y el resultado final se reservarán para construir etiquetas y evaluar resultados. Para determinar elegibilidad solo se comprobará si un retiro ya había ocurrido al corte; no se incorporará su fecha futura al vector de características. Los resultados inexistentes o inválidos se investigarán y no se convertirán automáticamente en reprobación.

3.1.4. Comparación de modelos y referencias

Se utilizarán regresión logística multinomial y Random Forest como clasificadores de referencia. Para cada algoritmo se compararán dos configuraciones: antecedentes estáticos conocidos al inicio, y los mismos antecedentes enriquecidos con actividad digital hasta el corte. Los modelos enriquecidos podrán ajustarse por corte; la versión estática conservará su estimación individual al no recibir información nueva.

El baseline principal será la configuración estática del mismo algoritmo. La selección de parámetros tendrá un esfuerzo comparable y se realizará antes de evaluar el conjunto final. Como referencia operativa adicional se propondrá ordenar por días desde la última actividad registrada, con desempate determinista; será una regla simulada, no un proceso institucional confirmado. La ventana y el manejo de ausencia de actividad se fijarán antes de la prueba final.

Las variables de desempeño académico acumulado, como notas de evaluaciones, quedarán fuera de la comparación principal para aislar el aporte de la interacción digital. Una extensión posterior podría incorporarlas, manteniendo explícito que respondería otra comparación. No se interpretará la superioridad frente al baseline estático como superioridad frente a todo sistema de seguimiento académico posible.

3.1.5. Evaluación técnica y éxito operativo

La métrica técnica principal será el área bajo la curva precisión–recobrado para la categoría de reprobación frente al resto (**PR-AUC**). Se reportarán también precisión y recobrado en las listas priorizadas, matriz de confusión entre las tres categorías y calibración de probabilidades. Se fijará la implementación de PR-AUC y se utilizará consistentemente. La exactitud global no será la única medida, porque puede ocultar errores en categorías menos frecuentes.

La evaluación principal de focalización se realizará en el día 56 con capacidad simulada del 10% de matrículas elegibles por edición. Para cada edición, K = piso(0,10 × N elegibles); se seleccionarán las K puntuaciones más altas, con desempate estable independiente del target. Las ediciones sin capacidad suficiente para una comparación interpretable se reportarán por separado. Se explorarán 5% y 20% como sensibilidad, sin elegir retrospectivamente el escenario más favorable.

Meta provisional: aumentar al menos un 10% relativo el número de casos de futura reprobación incluidos en la lista, respecto al baseline estático y a igualdad de K. Si TP_L y TP_E representan esos casos en la versión longitudinal y estática, la mejora será (TP_L − TP_E) / TP_E × 100. Si TP_E = 0, el porcentaje será indefinido y se informará la diferencia absoluta. Pasar de 40 a 44 casos constituye un 10% relativo; no equivale a evitar cuatro reprobaciones.

Los cortes anteriores mostrarán el balance entre anticipación y calidad predictiva. Las diferencias entre cortes pueden reflejar cambios en la población elegible, por lo que se informarán su tamaño y composición. En cada corte, ambas configuraciones se evaluarán sobre exactamente las mismas matrículas. Se presentarán resultados agregados y por edición, junto con incertidumbre mediante remuestreo agrupado por estudiante cuando sea viable.

La familia de modelo que sustentará la comparación principal se fijará con validación; ambos algoritmos se reportarán sin escoger al ganador usando la prueba final. El cumplimiento de la meta, la consistencia entre ediciones y el costo adicional de procesamiento se considerarán conjuntamente. Una mejora puntual e incierta no se presentará como garantía de generalización.

3.1.6. Umbral, acción y juicio humano

El umbral operativo será la puntuación del último caso que cabe dentro de K, no una probabilidad fija arbitraria. En una aplicación real, un tutor revisaría las alertas después de cada corte, contrastaría señales y contactos previos, y decidiría si corresponde orientación, tutoría o derivación. El modelo no determinará causas ni decisiones disciplinarias.

El resultado inmediato será una lista priorizada acompañada de actividad reciente, variación respecto al corte anterior e identificación de información insuficiente. Estas señales describirán asociaciones y no explicaciones causales. Los estudiantes que no aparezcan en la lista conservarían las vías habituales de apoyo.

3.2. Viabilidad técnica y de datos

3.2.1. Fuente, acceso y cobertura

OULAD es la fuente principal. El equipo confirma descarga y acceso, y la copia local cuenta con auditoría descriptiva y checksums. Su publicación describe siete módulos y 22 ediciones de 2013–2014, 32.593 registros estudiante–módulo–edición y 10.655.280 registros de interacción diaria [1]. Estas cifras describen la publicación. Los conteos locales y las poblaciones elegibles se presentan separadamente en la evidencia local.

Fuente	Acceso y contenido previsto	Cobertura y restricciones por verificar
studentInfo.csv	Archivo local presente y auditado descriptivamente. Antecedentes y final_result, que aporta la etiqueta.	Una fila por matrícula; categorías, duplicados, faltantes y disponibilidad real al inicio. No tratar una variable como inicial solo por estar en esta tabla.
studentVle.csv	Archivo local presente y auditado descriptivamente. Fecha relativa, recurso y cantidad de clics [2].	Agregación diaria por estudiante y recurso; volumen por edición, cobertura, ausencia de actividad y registros fuera de rango.
vle.csv	Archivo local presente y auditado descriptivamente. Características del recurso para contextualizar la actividad.	Consistencia de claves y tipos entre ediciones; no asumir idéntica oferta digital en todos los módulos.
courses.csv	Archivo local presente y auditado descriptivamente. Módulo, edición y duración.	Una fila por edición; fechas y duración para determinar horizonte y disponibilidad de etiquetas históricas.
studentRegistration.csv	Archivo local presente y auditado descriptivamente. Registro y retiro.	Una fila por matrícula; utilizar fechas de forma compatible con el corte y revisar inconsistencias.
assessments.csv y studentAssessment.csv	Identificadas en OULAD; no requeridas para el modelo principal.	Uso eventual para contexto; su contenido no se añadirá sin documentar temporalidad y nueva comparación.
Capacidad, costos e intervenciones tutoriales	No disponibles ni confirmados.	Se requieren registros institucionales para evaluar impacto real. Los cupos del estudio son supuestos de simulación.

La publicación y la documentación oficial describen el esquema y su licencia CC BY 4.0 [1], [2]. Se mantendrá la atribución y se trabajará con identificadores anonimizados. La existencia de una fuente pública no elimina la necesidad de revisar calidad y representatividad. No se incorporarán movilidad física, datos privados universitarios ni información externa para identificar estudiantes.

3.2.2. Preparación y características

La auditoría descriptiva generó el inventario de archivos, períodos, categorías, matrículas, personas únicas y clases del target. La cobertura semántica continúa pendiente. Las uniones utilizarán claves completas para evitar multiplicación accidental de filas. Se documentarán exclusiones y el número de registros que pasa cada filtro. Cuando no existan eventos de actividad, se distinguirá cero observado de cobertura desconocida antes de imputar.

Los antecedentes candidatos incluirán educación previa, intentos anteriores, créditos y contexto del módulo. Su uso dependerá de verificar que representan información disponible al inicio; cualquier campo ambiguo se excluirá del modelo principal o se declarará como supuesto comprobable. Los identificadores de estudiante y recurso no se usarán para memorizar personas. Los atributos demográficos se revisarán para auditoría de errores y se justificará por separado cualquier incorporación predictiva.

Se construirán características digitales acumuladas y por intervalos de igual duración: clics, días activos, días desde la última interacción, variedad de tipos de recurso y cambios entre quincenas. El primer corte no tendrá una tendencia entre dos quincenas completas; esa ausencia se representará explícitamente. Se distinguirán nivel y cambio: estabilidad de actividad no supone suficiencia, y una caída no identifica automáticamente riesgo.

La definición de intervalos, el tratamiento del día cero y la actividad anterior al inicio se fijarán en un diccionario antes de entrenar. Todo resumen se calculará sin registros posteriores al corte. Imputación, escalamiento, codificación y cualquier normalización aprendida se ajustarán únicamente con entrenamiento. La inferencia utilizará exactamente las mismas transformaciones.

3.2.3. Validación temporal y control de información futura

Se reservarán ediciones posteriores compatibles para prueba y se entrenará con ediciones previas del mismo módulo y período de inicio cuando existan. Una etiqueta de entrenamiento solo será válida si el módulo histórico ya había concluido antes de la predicción simulada. El año de inicio por sí solo no garantiza ese orden: se verificará también la duración y el momento de disponibilidad del resultado.

Dentro del histórico admisible se separará validación para ajustes, agrupando por estudiante y, cuando la cobertura lo permita, respetando el orden de ediciones. La evaluación principal se realizará con estudiantes no utilizados para ajustar el modelo; los repetidos entre entrenamiento y prueba se excluirán de la prueba principal y se contabilizarán. Todos los cortes de una misma matrícula permanecerán en la misma partición.

La auditoría determinará qué pares de ediciones permiten este diseño sin fuga. No se forzará la inclusión de todos los módulos. Si la cobertura es insuficiente, se acotará el estudio y se explicará su población de validez. La escasez de ediciones limita la certeza de generalización incluso si existen muchas filas de actividad.

3.2.4. Implementación y factibilidad

Se trabajará en Python desde Visual Studio Code, dentro de un entorno local con dependencias aisladas y versionadas. Los datos de actividad se procesarán por agregaciones para evitar cargar repetidamente todo el histórico. Se medirán memoria, tiempo de preparación e inferencia antes de decidir si es necesario reducir el subconjunto.

La solución separará preparación, entrenamiento, evaluación e inferencia. El modelo y sus transformaciones se conservarán juntos con la versión de datos, características y parámetros. La factibilidad se apoya en datos descargados y modelos delimitados, pero permanece condicionada a la auditoría y a una primera ejecución de procesamiento; se completó la auditoría descriptiva, pero el procesamiento de características y la inferencia siguen pendientes.

3.3. Viabilidad de negocio

3.3.1. Cambio del proceso y responsables

En el escenario de referencia, la institución dispone de una revisión inicial y responde a dificultades manifiestas o solicitudes. La propuesta incorpora una revisión quincenal de prioridades. El coordinador definiría capacidad y reglas de atención; los tutores revisarían contexto y decidirían el contacto; el responsable analítico controlaría calidad de datos y desempeño. Estos roles son propuestos y no representan participantes institucionales comprometidos.

El uso previsto comienza cuando se publica la lista correspondiente a un corte. El tutor revisa actividad y evolución, verifica si ya existe un contacto y decide una acción de apoyo. En una implementación real se registrarían fecha, duración, acción, respuesta y seguimiento. La información analítica no sustituye la conversación con el estudiante ni acredita una causa concreta de su dificultad.

3.3.2. Capacidad y simulación de la decisión

El escenario base admite revisar al 10% de matrículas elegibles por edición y corte. El supuesto simplificador es un costo equivalente por revisión; se analizarán también capacidades del 5% y 20%. No se convertirá el número de cupos en horas o dinero sin información institucional que lo sustente.

La comparación principal del día 56 evaluará la focalización de una lista de tamaño fijo. Como análisis complementario se reproducirán las cuatro listas usando la misma regla de capacidad para ambos enfoques. Cada revisión repetida consumirá un cupo y cada matrícula contará una sola vez

entre los casos correctamente identificados acumulados. También se informarán estudiantes únicos, pues una persona puede aparecer en más de un módulo.

Esta simulación permitirá examinar repetición de alertas y casos detectados por primera vez. No será equivalente a un programa real de tutorías: no modifica las trayectorias observadas ni supone que todas las personas seleccionadas aceptan apoyo. Se documentarán los presupuestos utilizados para evitar atribuir a la predicción una ganancia derivada de aumentar contactos.

3.3.3. Métricas de valor y límites de la evidencia

Pregunta	Métrica y evidencia
¿Qué tan bien predice?	PR-AUC, precisión, recobrado y calibración, utilizando resultados históricos observados.
¿Focaliza mejor la capacidad simulada?	Casos de futura reprobación incluidos a igual K, diferencias relativas y absolutas, omisiones y contactos repetidos.
¿Con cuánta anticipación identifica?	Tiempo entre primera selección y cierre del módulo. No representa el inicio real de las dificultades.
¿Actuar mejora resultados educativos?	En un piloto posterior: diferencia absoluta en proporción de aprobación entre grupos asignados, con intervalo de confianza; reportar también Fail, Withdrawn, participación, costos y posibles efectos adversos.

Para evaluar causalmente la oferta de apoyo, se propone el protocolo aleatorio posterior desarrollado en la revisión metodológica. Comparar políticas de selección sería una pregunta adicional con presupuesto equivalente. Se mediría la estrategia asignada y no solo quienes aceptaron tutoría, evitando confundir autoselección con eficacia. El protocolo requeriría acuerdo institucional y no forma parte de la ejecución actual.

El criterio de avance del prototipo combinará mejora de focalización, incertidumbre aceptable para continuar investigando y carga manejable en los escenarios. La reducción efectiva de reprobación, el ahorro y la transferencia a otra universidad no podrán concluirse únicamente de OULAD. Si la mejora no se sostiene, se recomendará conservar el baseline o revisar el diseño en lugar de afirmar éxito.

3.4. Riesgos y respuestas previstas

• **R1. Aporte longitudinal insuficiente — Técnico; severidad alta. Supuesto:** las nuevas características mejoran la focalización de forma consistente. **Verificación:** comparación emparejada por algoritmo y corte, diferencias absolutas y relativas e incertidumbre por edición. **Respuesta:** reportar el resultado negativo, conservar el baseline cuando corresponda y no justificar complejidad adicional sin evidencia.

• **R2. Información futura en características o entrenamiento — Técnico; severidad crítica. Supuesto:** toda entrada y etiqueta histórica usada para ajustar el modelo era conocida en la fecha simulada. **Verificación:** auditoría de cortes, fechas de retiro, finalización de ediciones, particiones y transformaciones. **Respuesta:** corregir el conjunto, reconstruir modelos y retirar conclusiones obtenidas con fuga.

• **R3. Falta de actividad confundida con falta de datos — Técnico; severidad alta. Supuesto:** los resúmenes representan actividad registrada comparable. **Verificación:** cobertura por edición y recurso, duplicados, faltantes y cambios de calendario. **Respuesta:** distinguir estados desconocidos, excluir fuentes o ediciones inconsistentes y mostrar información insuficiente en lugar de asignar riesgo sin sustento.

• **R4. Transferencia limitada — Técnico y de negocio; severidad alta. Supuesto:** las relaciones se mantienen en ediciones posteriores y poblaciones pertinentes. **Verificación:** evaluación por módulo, período y subgrupos con volumen suficiente. **Respuesta:** restringir el alcance declarado,

recalibrar o solicitar validación externa antes de una adopción institucional.

• **R5. Capacidad y carga irreales — Negocio; severidad alta. Supuesto:** la revisión propuesta es viable para los tutores. **Verificación:** sensibilidad de capacidad, contactos repetidos y, en una futura adopción, tiempos reales de revisión. **Respuesta:** ajustar frecuencia, listas y reglas de seguimiento; no presentar eficiencia monetaria sin datos de costos.

• **R6. Detección sin efecto del apoyo — Negocio; severidad alta. Supuesto:** identificar antes permite una intervención útil y aceptada. **Verificación:** piloto posterior con comparación de políticas, participación y resultados. **Respuesta:** limitar la conclusión a predicción y focalización, y revisar el servicio de acompañamiento antes de ampliar su uso.

• **R7. Errores desiguales o pérdida de confianza — Adopción; severidad alta. Supuesto:** las alertas son comprensibles y sus errores no perjudican desproporcionadamente a ciertos grupos. **Verificación:** análisis de falsos positivos y negativos por subgrupos y revisión del lenguaje de la interfaz; consulta a tutores en una etapa posterior. **Respuesta:** ajustar variables o reglas, mantener juicio humano y evitar etiquetas sancionatorias.

• **R8. Procesamiento o cobertura incompatibles con el MVP — Técnico y de alcance; severidad media-alta. Supuesto:** los archivos pueden procesarse y existen suficientes ediciones compatibles. **Verificación:** inventario y primera ejecución con medición de recursos. **Respuesta:** limitar módulos con criterios de calidad definidos antes de mirar resultados; preservar la comparación estática/longitudinal y documentar la menor generalización.

3.5. Alcance y MVP

3.5.1. Producto propuesto

Se propone un MVP de análisis y priorización académica que reciba datos históricos con esquema validado, genere estimaciones para los cuatro cortes y permita consultar listas y evolución del riesgo. Incluirá un informe comparativo y un mecanismo de inferencia reproducible. La forma concreta de interacción —interfaz local, reporte navegable o servicio demostrativo— se elegirá durante la implementación, sin comprometer Colab como entorno de ejecución final.

El despliegue será demostrativo en un entorno controlado y separado del entrenamiento. El usuario podrá seleccionar edición, corte y capacidad; observará las probabilidades, señales disponibles y advertencias de calidad. El resultado final observado se mostrará únicamente en la vista de evaluación retrospectiva, claramente separado de la información que habría existido al emitir la alerta.

3.5.2. Etapas y evidencias de terminación

Etapa	Trabajo y evidencia verificable
DATOS	Inventario, diccionario, claves y reglas de elegibilidad; reporte de cobertura, calidad y exclusiones; subconjunto reproducible.
EXPLORACIÓN / FEATURES	Análisis de clases y actividad por edición; construcción de antecedentes y ventanas; comprobaciones de que cambiar datos futuros no altera características de un corte anterior.
MODELO	Comparación estática/longitudinal con regresión logística y Random Forest, validación documentada, prueba reservada y reporte de métricas e incertidumbre.
DESPLIEGUE	Modelo y transformaciones versionados, inferencia desde entradas validadas y demostración ejecutable mediante instrucciones de instalación y uso.
MONITOREO	Registro de versión, faltantes, volúmenes, distribución de puntuaciones y tamaño de listas; desempeño cuando se incorporen etiquetas observadas.

El monitoreo se probará mediante reproducción histórica, no mediante conexión a una universidad. Se definirán rangos de referencia con entrenamiento y validación, sin atribuir a variaciones de datos una caída de precisión hasta disponer de resultados. Una entrada inválida impedirá emitir una predicción normal; cambios relevantes generarán una señal para revisión, no un reentrenamiento automático.

3.5.3. Criterios de aceptación y exclusiones

El MVP se considerará técnicamente completo si reproduce las transformaciones y predicciones, verifica el respeto de los cortes, utiliza las mismas poblaciones y presupuestos para comparar, conserva la prueba final independiente y entrega resultados trazables con sus limitaciones. El cumplimiento de la meta del 10% se informará por separado: finalizar correctamente el proyecto no equivale a confirmar la hipótesis.

Quedan fuera del alcance la integración con plataformas institucionales, la captura en tiempo real, el contacto con estudiantes, la ejecución de tutorías, decisiones disciplinarias, movilidad física, predicción de abandono institucional, demostración causal de impacto y cuantificación de ahorro sin datos. No se incorporarán modelos complejos de secuencias como requisito del MVP.

La fuente local se confirmó en datasets/. Antes de implementar se validarán los módulos y pares de ediciones elegibles para la evaluación temporal, las variables realmente disponibles al inicio y los recursos de ejecución. Estas verificaciones no cambian la selección de la idea, pero pueden ajustar su subconjunto de análisis. La propuesta breve conservará las decisiones esenciales, la evidencia de viabilidad y los riesgos en 1 a 2 páginas, conforme a los requisitos actualizados. Este documento ampliado conserva el detalle para continuar el proyecto.

Revisión metodológica vigente

• **Caso seleccionado:** riesgo de reprobación al cierre de un módulo, con OULAD. Universidad hipotética, sin socio institucional comprometido.

• **Unidad:** matrícula estudiante–módulo–edición. OBT futura: esa matrícula en un corte de observación; hasta cuatro filas por matrícula elegible.

• **Población inicial:** registrada hasta el inicio oficial. En cada corte, excluir solo retiros ya ocurridos; contabilizar exclusiones. No utilizar la fecha futura de retiro como predictor.

• **Salida:** probabilidades de Fail, Withdrawn y aprobación (Pass + Distinction). Ordenar la revisión por P(Fail). Retiro y abandono institucional son conceptos distintos.

• **Cortes:** días 14, 28, 42 y 56. Ocho semanas es observación temprana, no duración total del módulo. El horizonte termina al cierre de cada edición.

• **Modelos:** regresión logística multinomial y Random Forest. Comparar cada algoritmo con variables estáticas frente al mismo algoritmo enriquecido con actividad longitudinal. No agregar notas de evaluaciones al análisis principal.

• **Métrica técnica:** PR-AUC para Fail; complementar con precisión, recobrado, calibración e incertidumbre. Fijar la implementación de PR-AUC antes de comparar.

• **Meta:** al menos 10 % relativo más de futuras reprobaciones detectadas en el día 56, frente al baseline estático, con la misma población y capacidad. Es meta provisional; no garantía, resultado alcanzado ni 10 puntos porcentuales.

• **Presupuesto:** K = floor(0.10 × N_elegibles) por edición y corte, sensibilidad 5 % y 20 %. Es un cupo preventivo simulado; no es capacidad institucional medida. La tutoría habitual queda fuera de la

simulación: no se afirma que nueva atención adicional sea gratuita ni que exista personal reservado.

• **Umbral:** puntuación del último caso que cabe en K. Desempate estable sin consultar la etiqueta. Informar ediciones con K insuficiente; no elegir retrospectivamente el presupuesto que favorezca el modelo.

• **Error prioritario:** se considera provisionalmente más grave omitir casos futuros de reprobación, por la oportunidad de apoyo perdida. Las falsas alertas consumen cupos; costos relativos y prioridad requieren validación institucional.

• **Validez:** ediciones posteriores compatibles; etiquetas históricas maduras antes del instante simulado; estudiantes separados entre ajuste y prueba; todas las filas y cortes de una matrícula en la misma partición. Definir transformaciones y ajustes dentro del entrenamiento.

• **Juicio:** el sistema calcula y ordena; el tutor revisa siempre contexto y decide contacto, orientación o derivación. No sanciones automáticas ni contacto real en el MVP.

• **Tres niveles:** calidad predictiva; focalización simulada; impacto educativo posterior. No confundirlos.

Comparador operativo reproducible

Añadir una política simple de seguimiento: ordenar las matrículas elegibles por días desde la última interacción registrada hasta el corte, de mayor a menor, y asignar los mismos K cupos.

Antes de evaluar, fijar: tratamiento de quienes nunca registraron actividad, disponibilidad de actividad previa al inicio, distinción entre inactividad y cobertura desconocida, y desempate estable. Una opción de diseño es contar desde el inicio para quienes carecen de actividad y tienen cobertura comprobada; los estados desconocidos deben señalizarse y tratarse con una regla explícita común. Auditar esta opción antes de adoptarla.

Esta política ya usa actividad temporal: es un comparador operativo adicional, no un baseline estático ni un proceso institucional observado. No afirmar superioridad sobre OU Analyse. Mantener la comparación estática/longitudinal como prueba principal de la hipótesis.

Métricas: TP@K, precisión@K, recobrado@K, casos omitidos, primeras detecciones y anticipación hasta cierre. Para la comparación del día 56, mismo N y K. Para cuatro listas sucesivas, mismas reglas de capacidad; revisiones repetidas consumen cupos y cada matrícula se cuenta una sola vez en TP acumulados. Informar también estudiantes únicos.

Protocolo de impacto posterior, sin ejecutarlo en este PSet

• **Pregunta:** ¿ofrecer un programa definido de acompañamiento preventivo mejora la aprobación respecto de la atención habitual?

• **Población:** estudiantes elegibles identificados como en riesgo mediante una regla fijada antes de asignar la intervención; fecha de corte y ámbito de validez documentados.

• **Asignación:** aleatoria por estudiante a oferta de acompañamiento proactivo o atención habitual, con estratificación pertinente por módulo/riesgo. Resolver matrículas múltiples asignando a cada persona de manera coherente. Si se requiere aleatorizar por tutor o grupo para evitar contaminación, ajustar diseño, muestra e inferencia por agrupamiento.

• **Intervención:** contacto, evaluación de necesidades, tutoría y seguimiento con frecuencia y contenidos acordados. Conservar el apoyo habitual en ambos grupos.

• **Resultado principal:** proporción que aprueba al cierre (Pass + Distinction), con diferencia absoluta en puntos porcentuales e intervalo de confianza entre grupos asignados. Informar también Fail y Withdrawn para no confundir una baja de Fail con mayor retiro.

• **Análisis:** intención de tratar; no comparar solo quienes aceptaron tutoría contra quienes no la aceptaron. Registrar oferta, contacto, participación, otras ayudas y seguimiento. La aleatorización aborda confusión en expectativa; documentar contaminación e intervenciones concurrentes.

• **Muestra:** calcularla posteriormente según tasa inicial, efecto mínimo relevante, potencia, agrupamiento si corresponde y pérdidas esperadas. No inventar tamaño ni potencia.

• **Valor y recursos:** participación, tiempo y costo por estudiante y por aprobación adicional cuando los datos lo permitan; posibles efectos adversos o diferencias entre grupos.

• **Alcance de la inferencia:** este ensayo estimaría el efecto de ofrecer ese programa en esa población. No estima efectos individuales ni prueba automáticamente que la selección longitudinal sea mejor que otra política. Esa segunda pregunta requeriría una evaluación de políticas con presupuesto comparable.

• **Estado:** protocolo diseñado; ejecución fuera del MVP, condicionada a institución, capacidad, autorizaciones y datos nuevos.

Correspondencia de riesgos

Los ocho riesgos ampliados se agrupan sin cambiar sus supuestos: grupo R1 del memo y pitch = ampliados R1 y R4 (mejora y transferencia); grupo R2 = ampliados R2, R3 y R8 (fuga, cobertura y procesamiento); grupo R3 = ampliados R5 y R6 (capacidad e impacto); grupo R4 = ampliado R7 (equidad y confianza). Gravedades de los grupos: alta, crítica, alta y alta.

Evidencia local y límites de la auditoría

Auditoría local del 12 de noviembre de 2026: 7.052 Fail (21.64 %). 10.156 Withdrawn (31.16 %) y 15.385 aprobaciones (47.20 %). sobre 32.593 matrículas. En la población inicialmente registrada hasta el día 0, 6.980 Fail (21.60 %). 10.068 Withdrawn (31.16 %) y 15.266 aprobaciones (47.24 %). sobre 32.314 matrículas. Son matrículas, no personas únicas ni una tasa institucional actual.

Auditoría descriptiva de datos

Ejecutada el 12-nov-2026 desde los cinco CSV originales de datasets/. No modifica entradas, no entrena modelos y no ejecuta el pipeline. SHA-256, bytes, fecha local y conteos están en datasets/manifest.json. Fecha de descarga y versión específica del paquete no aportadas; la modificación local no acredita fecha de publicación.

Poblaciones y denominadores

Población	N	Fail	Withdrawn	Aprobación	K total	Sin actividad registrada
Original	32593	7052 (21.64 %)	10156	15385	—	—
Registro hasta día 0	32314	6980 (21.60 %)	10068	15266	—	—
Día 14	27881	6972 (25.01 %)	5643	15266	2779	1582
Día 28	27307	6972 (25.53 %)	5069	15266	2719	881
Día 42	26795	6972 (26.02 %)	4557	15266	2672	684
Día 56	26294	6972 (26.52 %)	4056	15266	2619	576

28785 personas únicas en la tabla original. Se excluyen de la población inicial 234 registros posteriores al día 0 y 45 fechas de registro ausentes. No se imputaron estas últimas como registro temprano. En cada corte se excluye retiro con fecha <= corte; se mantienen retiros futuros. K total es la suma de floor(0.10 × N) por edición, no floor sobre el agregado.

Los conteos por módulo y edición, para original, inicial y cada corte, se conservan en poblaciones-por-edicion.csv. Numeradores: clases de final_result, agrupando Pass y Distinction; denominadores: filas elegibles según regla. Las matrículas sin eventos <= corte se preservan y no se equiparan automáticamente a inactividad: la cobertura real de registro debe comprobarse. Se incluye actividad de fechas negativas como observada antes del corte.

Claves, relaciones y calidad

• studentInfo: {"rows": 32593, "duplicate_keys": 0, "missing_key_values": 0}.

• studentRegistration: {"rows": 32593, "duplicate_keys": 0, "missing_key_values": 0}.

• courses: {"rows": 22, "duplicate_keys": 0, "missing_key_values": 0}.

• vle: {"rows": 6364, "duplicate_keys": 0, "missing_key_values": 0}.

• info_registration: {"rows_after": 32593, "unmatched": 0, "registration_without_info": 0}.

• studentVle: {"rows": 10655280, "orphan_enrollment_rows": 0, "orphan_resource_rows": 0, "negative_click_rows": 0, "date_min": -25, "date_max": 269, "duplicate_keys_within_chunks": 2195910, "global_daily_duplicate_check": "pendiente: conteo por chunks no demuestra unicidad global"}.

• courses_relation: {"info_without_course": 0}.

Completitud por columna

• studentInfo: {"code_module": 0, "code_presentation": 0, "id_student": 0, "gender": 0, "region": 0, "highest_education": 0, "imd_band": 1111, "age_band": 0, "num_of_prev_attempts": 0, "studied_credits": 0, "disability": 0, "final_result": 0}.

• studentRegistration: {"code_module": 0, "code_presentation": 0, "id_student": 0, "date_registration": 45, "date_unregistration": 22521}.

• courses: {"code_module": 0, "code_presentation": 0, "module_presentation_length": 0}.

• vle: {"id_site": 0, "code_module": 0, "code_presentation": 0, "activity_type": 0, "week_from": 5243, "week_to": 5243}.

• studentVle: {"code_module": 0, "code_presentation": 0, "id_student": 0, "id_site": 0, "date": 0, "sum_click": 0}.

Interpretación y pendientes

La unión studentInfo–studentRegistration conserva una fila por matrícula, con validación one_to_one. Las relaciones de actividad se contrastaron con matrícula y recurso usando sus claves completas. La auditoría de duplicados diarios por chunks no demuestra unicidad global: ese test sigue pendiente y no se aplicó deduplicación. No se alteraron datos.

Fechas negativas pueden representar registro o interacción previa al inicio y no son por sí mismas inválidas. Pendientes: cotejar intervalos por duración de edición y disponibilidad de recursos; validar inconsistencias entre retiro y etiqueta; comprobar calendario real, maduración de etiquetas y pares temporales utilizables; confirmar comparabilidad y completitud de cobertura. Valores válidos no demuestran exactitud externa. No hay métricas predictivas ni evidencia de efecto de tutorías.

Reproducción

Desde la raíz: .venv/bin/python pset-01/scripts/auditar_datos.py. Ruta alternativa: añadir --data-dir /ruta/autorizada. La ruta por defecto se deriva del script, no del directorio actual. El script falla ante archivos o claves principales incompatibles. Consultar requirements.txt para versiones usadas.

Continuidad con PSet 2

Diseño pendiente: Fuente → Kestra → Raw → dbt/Bronze → dbt/Silver → dbt/Gold → Spark/OBT, persistido en Snowflake. La OBT tendrá grano matrícula–corte. El pipeline, los modelos y el MVP no se han implementado. El documento de contrato fija elegibilidad antes de actividad y separa target de predictores. No se ejecutaron servicios ni recursos cloud.

Guía del pitch

Seis diapositivas: oportunidad de apoyo, magnitud auditada, decisión quincenal, viabilidad y MVP, beneficio ilustrativo y riesgos, solicitud y criterios de avance. El texto visible exacto y las notas se conservan en pset01-presentacion.md. La comparación 40 a 44 es ilustrativa; el piloto posterior mide aprobación por asignación.

Registro de cambios y sincronización

12-nov-2026: reconciliación del respaldo completo, auditoría descriptiva local, especificación de recencia, capacidad y protocolo posterior. Colab fue un antecedente de trabajo; no se proporcionó URL ni sesión autenticada identificable para respaldar, comparar y sincronizar sus celdas. Sincronización remota pendiente. Esta fuente local es la base controlada.

Referencias

[1] J. Kuzilek, M. Hlosta y Z. Zdrahal, “Open University learning analytics dataset,” *Scientific Data*, vol. 4, art. núm. 170171, nov. 2017, doi: 10.1038/sdata.2017.171 (https://doi.org/10.1038/sdata.2017.171).

[2] The Open University, “Open University Learning Analytics dataset,” *OU Analyse*. [En línea]. Disponible en: https://research.stem.open.ac.uk/ouanalyse/dataset/. [Consultado: 28-oct-2026].

[3] S. Tan et al., “Icentia11k Single Lead Continuous Raw Electrocardiogram Dataset,” versión 1.0, *PhysioNet*, abr. 2022, doi: 10.13026/kk0v-r952 (https://doi.org/10.13026/kk0v-r952).

[4] S. Tan et al., “Icentia11K: An Unsupervised Representation Learning Dataset for Arrhythmia Subtype Discovery,” en *Computing in Cardiology (CinC)*, 2021. [En línea]. Disponible en: https://www.cinc.org/2021/Program/accepted/229_Preprint.pdf. [Consultado: 28-oct-2026].

[5] The Open University, “OU Analyse.” [En línea]. Disponible en: https://research.stem.open.ac.uk/ouanalyse/. [Consultado: 11-nov-2026]. Describe el flujo de alertas como antecedente operativo, sin evidencia causal para este proyecto.

[6] E. P. Bettinger y R. B. Baker, “The Effects of Student Coaching in College: An Evaluation of a Randomized Experiment in Student Advising,” *Educational Evaluation and Policy Analysis*, vol. 36, no. 1, pp. 3–19, 2014. Resumen del estudio publicado por AERA: https://www.aera.net/Newsroom/Recent-AERA-Research/The-Effects-of-Student-Coaching. [Consultado: 11-nov-2026]. Acompañamiento individualizado y persistencia; su efecto no es directamente extrapolable a tutoría académica específica ni a OULAD.

[7] J. Klenke et al., “Effects of Early Warning Emails on Student Performance,” arXiv:2102.08803, versión revisada 2023, doi: 10.48550/arXiv.2102.08803. https://arxiv.org/abs/2102.08803. [Consultado: 11-nov-2026]. Los autores describen un efecto positivo estimado con poca precisión; no establece eficacia universal de las alertas.